Asistente antifraude

Le ayudamos a reconocer mensajes que intentan engañarle, sin abrir nunca sus enlaces.

Hackfinance · BEST UC3M · noviembre de 2026 · Prototipo académico · Nombre definitivo del producto: pendiente

El problema

Las estafas por correo y SMS suplantan a bancos, a empresas de paquetería, a la Administración o a familiares para conseguir claves, códigos de un solo uso (OTP), datos de tarjeta o transferencias. Cada vez son más convincentes, sin faltas de ortografía y con enlaces que imitan webs oficiales. Las personas mayores y con poca experiencia digital son las más expuestas.

La solución

Un asistente que revisa los mensajes que el usuario elige y le explica, en español llano:

✓ BAJO | ⚠ MEDIO | ⛔ ALTO | ? NO CONCLUYENTE

- **Qué nivel de riesgo** tiene el mensaje, siempre con icono y texto, nunca solo con color, y **sin porcentajes inventados**.
- **Por qué**: evidencias concretas con citas literales del mensaje. Y **qué no se ha podido comprobar**.
- **Qué hacer**: no compartir códigos y llamar al banco al teléfono de siempre. **La decisión es siempre del usuario.**

Cómo funciona

1. **Reglas deterministas** sobre el texto: peticiones de claves u OTP, urgencia, cambio de cuenta, familiar con número nuevo, inversión milagrosa, órdenes ocultas para la IA…
2. **Análisis pasivo de enlaces y remitente**: dominios que imitan al banco, texto del enlace distinto de su destino, acortadores, respuestas a otro dominio y autenticación del correo.
3. **IA (Claude), opcional**: aporta contexto con citas verificadas literalmente. Nunca decide sola.
4. **Motor de riesgo determinista**: fija el nivel. **Un error nunca da «BAJO»**, y una petición de claves u OTP nunca se considera segura.
5. **Alertas en dos fases**: un aviso preventivo inmediato y después el resultado explicado.

Por qué es diferente

- **Explica y reconoce sus límites**: separa el nivel, las evidencias y las incertidumbres.
- **Pensado para personas mayores**: texto y botones grandes, contraste alto, manejo completo con teclado y sin tecnicismos.
- **Privacidad**: funciona en el ordenador del usuario. Oculta códigos, tarjetas, IBAN, DNI y teléfonos antes de usar la IA, y no guarda el texto de los mensajes.
- **Seguro por diseño**: no visita enlaces, resiste los mensajes que intentan manipular a la IA y protege el acceso local con un código de un solo uso, cookie segura, CSRF y CSP estricta.

Modelo y viabilidad

Cliente: **bancos españoles**, como capa de protección para sus clientes (marca blanca en el futuro). El banco no recibe los mensajes personales. Las reglas no tienen coste por mensaje y la IA solo se usa en los mensajes sospechosos. El coste real por análisis con IA **no está medido todavía**: hace falta una prueba con presupuesto.

Estado real del prototipo

Funciona hoy (probado)	Preparado, probado solo con simulaciones	Pendiente
Análisis manual (texto y `.eml`), enlaces, reglas, motor, alertas, interfaz accesible y modo de demostración con datos ficticios. 674 pruebas automáticas.	Cliente de Claude (con salida estructurada y citas verificadas) y conector de Gmail (lectura y sondeo de mensajes nuevos).	Conexión real con Gmail y Claude (credenciales y presupuesto; la IA está desactivada y con 0 USD autorizados), dominios completos de bancos reales (hoy, solo la web del registro del Banco de España) y evaluación independiente con un conjunto sellado.

Las métricas del conjunto de desarrollo solo sirven para ajustar el sistema: no son una evaluación independiente y no se presentan como rendimiento real. Todos los ejemplos usan datos ficticios («Banco Ficticio», dominios reservados `.example`/`.test`).